



# PREDICCIÓN METEOROLÓGICA MEDIANTE REDES NEURONALES

Diana Lucía Poma Lima

e-mail: [dlpoma@utpl.edu](mailto:dlpoma@utpl.edu)

Loja-Ecuador

**RESUMEN:** *Los pronósticos meteorológicos son áreas desafiantes en la investigación. En el presente trabajo de predicciones he propuesto la utilización de redes neuronales ya que son de gran ayuda para este tipo de problemas. Los parámetros meteorológicos como la velocidad del viento, punto de rocío, temperatura, humedad, etc., son características extraídas de una base de datos de un periodo. El método que aplicare utiliza alimentación hacia adelante con redes neuronales artificiales para el aprendizaje supervisado, utilizando datos registrados de una estación meteorológica de la costa Ecuatoriana. La red neuronal a entrenar se la utilizara para predecir condiciones climáticas futuras en nuestro país. Con los resultados obtenidos se podrá observar que el modelo basado en características específicas puede hacer predicciones.*

**PALABRAS CLAVE:** Predicciones meteorológicas, redes neuronales artificiales, perceptrón multicapa, backpropagation.

## 1 INTRODUCCIÓN

En el presente trabajo se brinda una solución práctica al problema de las predicciones meteorológicas, por lo tanto las predicciones meteorológicas son actividades que se llevan en institutos especializados en estos fenómenos, como por ejemplo el INOCAR en Ecuador.

Para realizar las predicciones meteorológicas he decidido utilizar redes neuronales Artificiales en conjunto con la herramienta WEKA.

Para el entrenamiento de las redes utilizare el método de perceptrón multicapa ya que es un método supervisado que se basa en la corrección a partir de una decisión y la otra se base en la optimización de un criterio de coste.

Con la aplicación de las RNA, se resuelve el problema de la complejidad de los modelos de predicción tradicionales, a partir de los factores que realmente afectan la tranquilidad de las ciudades del país. Con el software WEKA se realizara la predicción meteorológica de una zona determinada empleando datos meteorológicos de un año con un error de predicción aceptable.

## 2 PLANTEAMIENTO DEL PROBLEMA

En la actualidad vivimos en un mundo donde los cambios meteorológicos nos están afectando a todos y por tanto se debe estar preparado ante las fuertes precipitaciones climáticas que afectan a nuestro país. Como es de nuestro conocimiento durante estos últimos años los cambios meteorológicos han sido muy irregulares debido a diversos factores externos como la destrucción de la capa de ozono, el efecto invernadero, la acidificación del medio ambiente, etc.

En el Ecuador el régimen de precipitaciones meteorológicas en condiciones normales depende de la región natural, por ende una de las regiones más afectada es la región Litoral seguida de la región interandina. [14]

Con los datos que recaban de las estaciones meteorológicas no es suficiente para prevenir y predecir los cambios que se vienen, por tanto la respuesta no es tan ágil como quisiéramos.

En los servicios meteorológicos, piensan que todavía las soluciones pueden encontrarse en el desarrollo de los sistemas tradicionales, pero existen otra serie de factores que condicionan el futuro de las predicciones meteorológicas como son las redes neuronales artificiales con aprendizaje supervisado.

## 3 ESTADO DEL ARTE

### 3.1 REDES NEURONALES ARTIFICIALES

Las Redes neurales artificiales (RNA) trabajan de la manera que trabaja nuestro cerebro. básicamente es un conjunto de neuronas (algo como 10 a 100 mil millones) conectadas, cuando nosotros aprendemos, algunas de esas conexiones se ponen más fuertes, así si nosotros vemos algo con nuestros ojos, esa información tomará un camino a través de las neuronas, y finalmente nosotros reconocemos el objeto que nosotros simplemente hemos visto, como por ejemplo: cuando se bebe alcohol, reduce la velocidad de las conexiones y los desarregla a un cierto sector de neuronas retrasando la reacción del estímulo de salida.[7]

Los conceptos básicos de un RNA son que la Red está formada por capas, estas capas son para la



Entrada y salida podría haber también algunas capas ocultas cada capa conforma un conjunto de nodos.

Todos los nodos almacenan un valor llamado activación, y posiblemente un error, cada nodo de una capa conectará a todos los nodos de la próxima capa.

Las redes más simples sólo tienen una capa de la entrada y una capa del rendimiento, así que cada nodo de la capa de la entrada se unirá a cada nodo de la capa del rendimiento, cada uno guarda un valor denominado peso.




Fig.1 Perceptrón Multicapa con más de una capa de neuronas [8]

La conexión de las redes normalmente tienen 3 capas: Entrada, Oculta, y Rendimiento. Los nodos de la entrada conectan a oculta, y los nodos de oculta conectan al Rendimiento. Así, que es un sistema de Feed Forward, mientras se está moviendo de la entrada al rendimiento se puede tener múltiples capas ocultas, pero tener una simplemente suele ser muy común. [7]

### 3.2 ARQUITECTURA DE UNA RED NEURONAL

Los elementos básicos comentados anteriormente se pueden conectar entre sí para dar lugar a las estructuras neuronales.

Cada neurona de manera individual posee un número de entradas, un nodo de procesamiento y una única salida, cada conexión entre neuronas está asociada con un peso. [9]




Fig. 2 Estructura de una neurona donde:  $X$  denota la nomenclatura usada para denotar las entradas,  $W$  para los pesos y  $U$  para la salida generada por la neurona. [9]

Las redes neuronales tienen básicamente dos ciclos de funcionamiento Forwardpropagation y Backpropagation, en el primero la red establece la forma como responde a las entradas presentadas a esta y en el segundo paso se establece la modificación de los pesos de la red que finalmente se verá reflejado en el aprendizaje de la red neuronal. [1]

### 3.3 ENTRENAMIENTO DE UNA RNA

El entrenamiento requiere la presencia repetida de un número relativamente amplio de patrones que permitan que la red aprenda, haciendo modificaciones en los pesos de las conexiones por medio de alguna regla de aprendizaje.

El tipo de aprendizaje más sencillo consiste en presentar patrones de entrada a la red junto a los patrones de salidas deseados, para cada patrón de entrada. A este tipo de aprendizaje se lo denomina aprendizaje supervisado.

Dentro del entrenamiento supervisado se encuentra las siguientes categorías:

- Aprendizaje por Corrección de Error
- Aprendizaje por refuerzo
- Aprendizaje Estocástico

Como ya se había mencionado el tipo de red a utilizar en el presente proyecto es la red perceptrón multicapa, por lo que es necesario describir el algoritmo de entrenamiento Backpropagation utilizado para este tipo de red.

### 3.4 EL PERCEPTRÓN MULTICAPA

El perceptrón es una clase de feed-forward en el que todos y cada conexión debe terminar en un nodo, en la capa más alta de la que comenzó. Al describir el perceptrón se refiere a una red con  $N$  capas de peso y con  $N$  capas del perceptrón.

Un perceptrón multicapa es una red de retro propagación, compuesta de varias capas de neuronas entre la entrada y la salida de la red, esta permite establecer regiones de decisión más complejas que las de los dos semiplanos, como lo hace el perceptrón simple. [10]

Las redes neuronales son una simplificación matemática basada en el proceso estímulo/respuesta de las neuronas. Son capaces de aprender o modelar la relación existente entre sus entradas y salidas mediante la modificación de los valores de los pesos de las conexiones que unen las entradas con las neuronas y las neuronas entre sí.

El problema de este tipo de estructura es que solo sirve para resolver problemas de complejidad lineal (relación lineal entre entradas y salidas), de ahí la



necesidad de introducir capas de neuronas ocultas y dar lugar al perceptrón multicapa, como el que hemos usado.

El problema de entrenar las neuronas de las capas ocultas para actualizar los pesos de sus conexiones se resuelve con el algoritmo de Backpropagation (retro-propagación). [13]

### 3.5 BACKPROPAGATION

El algoritmo de backpropagation es uno de los algoritmos más populares para el entrenamiento de redes neuronales; se aplica extensivamente y muestra un desempeño óptimo.

En la práctica sin embargo este algoritmo puede presentar dos dificultades: Velocidad de convergencia lenta y no siempre se garantiza encontrar el mínimo global de la función de error, sin embargo nuevos algoritmos pueden corregir estas dificultades. [10]

El algoritmo de aprendizaje backpropagation es un algoritmo de descenso por gradiente que retro propaga las señales desde la capa de salida hasta la capa de entrada optimizando los valores de los pesos sinápticos mediante un proceso iterativo que se basa en la minimización de las funciones de coste. [9] Por ello, puede dividirse el algoritmo en dos fases:

- Propagación hacia delante.
- Propagación hacia atrás.

Una red neuronal muy eficaz para resolver fundamentalmente problemas de reconocimiento de patrones es la red neuronal de propagación hacia atrás, en inglés backpropagation network.




Fig. 3 Esquema de la arquitectura de las redes neuronales Backpropagation.

En la red de la fig. 3, se interconectan varias unidades de procesamiento en capas, las neuronas de cada capa no se interconectan entre sí. Sin embargo, cada neurona de una capa proporciona una entrada a cada una de las neuronas de la siguiente capa, esto es, cada neurona transmitirá su señal de salida a cada neurona de la capa siguiente. [12]

### 3.6 FUNCIONAMIENTO DEL ALGORITMO

El algoritmo backpropagation sigue algunos pasos los cuales nos indican cómo funciona este algoritmo; por tanto el funcionamiento es de la siguiente manera:

1. Inicializar la red con pesos aleatorios
2. Para todos los casos de entrenamiento:
  - Presentar las entradas a la red y calcular las salidas.
  - Para todas las capas (empezando con la capa de salida, hacia la capa de entrada:
3. Comparar la salida de la red con la respuesta correcta (función de error)
4. Adaptar los pesos en la capa correspondiente
  - Evaluación del nivel de error generado al presentar cada uno de los patrones a la red, si se cumple el criterio de parada se detiene el entrenamiento, si no es así se vuelve al paso 2a.
5. Si el ciclo de propagación reversa (Backpropagation) renueva los valores de los pesos de la red en general y la retro-propagación del error desde la capa de salida hacia las demás capas ocultas de la red.

Si bien uno de los valores recomendados es 0.1, este comportamiento no es inusual dado que cada caso de entrenamiento de una red neuronal es único, aun cuando existen ciertas generalidades en los parámetros de entrenamiento estos no siempre son aplicables o no generan los mejores resultados. [12]

## 4 HERRAMIENTAS

Para la realización de este proyecto use el programa de código abierto Weka y código java para dar formato a los ficheros de entrada al software Weka.

Además la utilización de una base de datos pequeña o conjunto de datos para el entrenamiento de los mismos.

## 5 TRABAJOS RELACIONADOS

En estos últimos años se cuenta con varios trabajos relacionados con la predicción de series de tiempo utilizando redes neuronales artificiales, de los cuales podemos mencionar los siguientes:

- Predicción de acciones. Consiste en el desarrollo de una red neuronal capaz de realizar la predicción del precio de las acciones para un número dado de compañías. Esta predicción se realiza mediante redes alimentadas hacia adelante, y el objetivo en este particular caso es predecir el siguiente valor en la serie de tiempo: es decir el próximo precio de la acción. [2]



- Predicción de tráfico vehicular. Utiliza redes neuronales recurrentes para la predicción a corto plazo del tráfico en una carretera, a fin de prevenir congestiones y tener un control del acceso a la autopista. Para esto Ulbricht utiliza datos estimados de otros días con propiedades similares; los resultados se obtuvieron con una red multi-recurrente, y se pudo comprobar que las redes neuronales resolvieron este tipo de predicción y obteniendo mejores resultados que los métodos estadísticos convencionales [3].
- Predicción del tráfico en una intersección. Un marco conceptual de la predicción de choque en línea y sistema de prevención de las intersecciones semaforizadas se propone. Un sistema lógico de inferencia difuso es desarrollado para realizar la predicción en línea de colisión, que es la base para la aplicación de la colisión intersección de alerta / tecnologías de prevención. Se demostró que las redes neuronales con exactitud pueden predecir el volumen y la ocupación en un minuto por adelantado. Se utiliza una red neuronal multicapa entrenándose mediante backpropagation, ayudándose de una rampa de medición de lógica difusa para realizar la predicción. El riesgo se cuantifica mediante tres entradas difusas para el modelo, el momento de la colisión, la severidad del accidente y la percepción local de los controladores. Índice de Percepción e índice de severidad se integran a fin de reflejar las características del conductor del vehículo de seguridad del sistema. [4]
- Predicción de la transición mensual del índice de precios de acciones. Usando recurrencia y backpropagation, la red neuronal es entrenada para aprender conocimiento experimental y para predecir la transición de precios de acciones, Kyoung toma como entrada principal algunos indicadores económicos, obteniendo así la transición relativa de la composición del índice de precios de acciones, con datos económicos de ocho, como la predicción del crecimiento mensual o la caída del índice del precio de acciones. Los resultados indican que las redes neuronales son herramientas eficientes para la predicción del precio de las acciones. [5]
- Predicción de Tornados. Marzban y otros se basa en atributos obtenidos de un radar Doppler, el cual observa diferentes fenómenos que a la larga llegan a producir tornados. Las tormentas eléctricas algunas veces llegan a producirlos, pero no siempre son antecedente de ello. Una red neuronal alimentada hacia adelante es usada para diagnosticar cuales fenómenos detectados por el radar llegarán a producir un tornado. La red neuronal es diseñada para la identificación del *tornado-yielding*, con ese fin, se desarrollaron procedimientos para determinar el tamaño del conjunto de entrenamiento y el número de nodos ocultos necesarios para el funcionamiento óptimo. Se mostró que la red neuronal encontrada de este modo supera un algoritmo basado en reglas. [6]

## 6 METODOLOGÍA Y MODELO

Los datos diarios de entrada para la realización del modelo de Predicción Climática, se obtuvieron de la estación meteorológica de Salinas que pertenece al proyecto Weather Underground, la cual realiza lecturas diarias. La base de datos que se obtuvo, está compuesta por datos de aproximadamente un año.

Una vez obtenidos los datos se procede a clasificar las variables que se necesitara, como se puede observar en la tabla 1.

Fecha	Temperatura	Punto de Roció	Humedad	Visibilidad	Viento Max	Viento Min
08/07/2009	24	0	0	12,0	7	7
13/07/2009	25	0	0	15,0	11	11
14/07/2009	24	21	77	15,0	6	4
15/07/2009	...	...	...	...	...	...
22/04/2010	29	22	76	12,0	15	12

Tabla 1 Variables de entrada para la RNA

Para poder subir los datos a Weka se necesita, que el archivo tenga extensión *arff* ya que es la extensión principal de Weka. También acepta otras extensiones pero es preferible que sea la predeterminada por Weka para no tener problemas en la clasificación de los datos.

Una vez subidos los datos en el software Weka procedemos a la clasificación, eligiendo el algoritmo con que se va a trabajar, en este caso Backpropagation.

## 7 APLICACIÓN

El análisis referente al moldeamiento y predicción que se presenta en el presente proyecto se basa en las predicciones meteorológicas basándose en la temperatura.

La serie de variaciones meteorológicas es calculada por la empresa Weather Underground. Los datos que se utilizo son de aproximadamente un año, con la finalidad de obtener una buena predicción.

El principal interés es observar cómo el modelo captura los resultados de la serie y como reflejan sobre el período de predicción.

La razón por la cual se consideran seis observaciones para la predicción, radica en que la presencia de cambios estructurales puede hacer que el modelo no recoja adecuadamente la los datos verdaderos y por ende, podrán presentar elevados errores en el pronóstico predictivo.

De esta forma, el escoger un número adecuado de las neuronas que conformaran las capas (entrada,





oculta, salida), mejorara la capacidad predictiva del modelo, permitiendo una mejor predicción.

Respecto a las predicciones realizadas, el punto importante en la interpretación de los resultados son las formas de medición del error para la predicción y así establecer las comparaciones, estos errores son:

- Error cuadrático medio
- Error absoluto relativo

## 8 RESULTADOS Y DISCUSIÓN

El presente proyecto propone una red neuronal de tipo perceptrón multicapas que optimiza tanto la matriz de pesos como el número de neuronas ocultas. En el modelo que presento, inicialmente utilicé cuatro neuronas ocultas con dos de entradas y dos de salida, gradualmente voy reduciendo las neuronas ocultas, y de esta manera se va optimizando la matriz de pesos mediante el algoritmo backpropagation.

Una vez que la red converge analizo su funcionamiento y si este no es el esperado voy eliminando una neurona de la capa oculta. Este proceso se repite hasta obtener el funcionamiento deseado.

Los resultados obtenidos muestran que el modelo presenta un funcionamiento muy bueno, es decir cuando éste tiene un número óptimo de nodos en la capa oculta, disminuye la complejidad computacional durante la etapa de entrenamiento.

Generalmente el aprendizaje de una red neuronal generalmente se produce mediante la formación de una serie de entrada / salida de datos (patrones), donde la formación del algoritmo backpropagation ajusta el vínculo pesos. La relación peso, almacena el conocimiento necesario para resolver problemas específicos en este caso las predicciones.

El modelo de predicciones meteorológicas se implementó como una red neuronal del tipo backpropagation, el cual emplea una función sigmoidea, con tasa de aprendizaje 1, tasa de momento 0.5 y el parámetro 0.5.

Se observa en la imagen la función de activación utilizada fue la sigmoidea, que entrega valores para temperaturas en todo el intervalo [0,1].

Como primer punto, parto de una red neuronal (2,4,2) que se idéntica con 2 neuronas de entrada, 4 neuronas para la capa oculta y 2 neuronas de salida definida por la 10ma, 27va, 17va orden de rezagos de la serie y seis variables que identifican al modelo.




Fig. 4 Red Neuronal predicciones Meteorológicas (2,4,2)

Esta red está realizada con una validación cruzada de 3 y 10 veces, respectivamente. Entre el número de validación cruzada que le dé, también depende que haya una buena predicción y el porcentaje de error sea mínimo. El número de iteraciones que utilice en todos los casos es de 500-

Como podemos apreciar en la fig. 5 el error cuadrático medio es menor en el caso de la validación cruzada con 10 es de 1.94, mientras que la validación cruzada con 3 es de 2.79. Por lo tanto el error relativo es de 58.5 % en el cruce de 10 veces, y con un 101,69 % en el cruce de 3. Podemos concluir que a mayor número de cruces el error es mínimo.

=== Summary ===		Cross - Validation = 3
Correlation coefficient	0.0304	
Mean absolute error	2.4077	
Root mean squared error	2.7986	
Relative absolute error	101.6932 %	
Root relative squared error	101.8194 %	
Total Number of Instances	272	
=== Summary ===		Cross - Validation = 10
Correlation coefficient	0.7245	
Mean absolute error	1.3867	
Root mean squared error	1.9437	
Relative absolute error	58.5497 %	
Root relative squared error	70.6473 %	
Total Number of Instances	272	

Fig. 5 Resultados RNA (2, 4,2) con cross-validation 3 y 10 veces

Una vez analizados los datos con diferente número de neuronas de capas ocultas, se puede concluir que a menor número de neuronas en las capas ocultas el porcentaje de error relativo es mínimo en el aprendizaje de la red neuronal.

Es decir se ve la evolución de los mismos cuando se disminuyen el número de neuronas de la capa oculta. Deduciendo que la reducción en el número de neuronas de la capa mencionada produce la disminución en el porcentaje de error del aprendizaje.



Para comprobar lo dicho anteriormente se realizó un análisis de siete redes neuronales, con N capas de neuronas.

N Capas	Error Cuadrático	Error Relativo
RNA (2,4,2)	1,9437	58,5497 %
RNA (2,3,2)	2,7608	92,2629 %
RNA (2,2,2)	2,6967	88,5546 %
RNA (2,1,2)	1,7978	56,275 %
RNA (2,0,2)	1.5621	50,7797 %
RNA (3,0,3)	1,4323	45,8524 %
RNA (3,1,3)	1,8794	58,3769 %

**Tabla 2 Resultados de las RNA con Ncapas**

En los resultados obtenidos se puede observar (Tabla 2) que el error cuadrático medio y el error absoluto relativo con menores valores son en las redes neuronales (3,0,3) y (2,0,2), esto se debe a la reducción de las neuronas de la capa oculta.

Además se realizó un segundo análisis en una herramienta diferente a Weka, llamada Neural Tools con una red neuronal de (2,0,2) los resultados que se obtuvieron son mayores a los que arrojo la herramienta Weka.

<b>Summary</b>	
<b>Net Information</b>	
Name	BDPM
Configuration	GRNN Numeric Predictor
Location	This Workbook
Independent Category Variables	0
Independent Numeric Variables	5 (PtoRocio®, Humedad%, Visibilidad(Km), VientoMax(km/h), VientoMin(km/h))
Dependent Variable	Numeric Var. (Temperatura)
<b>Training</b>	
Number of Cases	218
Training Time	0:00:00
Number of Trials	98
Reason Stopped	Auto-Stopped
% Bad Predictions (30% Tolerance)	0,0000%
Root Mean Square Error	1,059
Mean Absolute Error	0,7723
Std. Deviation of Abs. Error	0,7238
<b>Testing</b>	
Number of Cases	54
% Bad Predictions (30% Tolerance)	0,0000%
Root Mean Square Error	1,108
Mean Absolute Error	0,8769
Std. Deviation of Abs. Error	0,6776
<b>Data Set</b>	
Name	Data Set #1
Number of Rows	272
Manual Case Tags	NO

**Fig. 6 Resultados con la herramienta Neural Tools**

En la Fig. 6 se puede ver que el error cuadrático medio es de 1.108 y el error absoluto relativo es 67.76%. Mientras que en Weka los resultados son 1.56 y 50.77% de los errores cuadrático medio y absoluto relativo respectivamente. Como conclusión se puede decir que el error absoluto relativo de la herramienta Neural Tools es mayor que en Weka, obteniendo mejores resultados de predicción y un menor porcentaje de error con Weka.

Por lo tanto cada vez que se va realizando la clasificación, en un orden diferente, los pesos de las conexiones aumentan velocidad durante el proceso, ocasionando un lento descenso del error producido en el nivel de salida, por lo tanto la red neuronal presenta un buen comportamiento, debido al aprendizaje que tiene y a la evaluación del error que comete la red.

## 9 CONCLUSIONES

Una vez terminado el estudio, podemos concluir que el análisis realizado con los datos meteorológicos puede ser realmente útil, ya que nos permite realizar sondeos posteriores en nuestro cambiante clima y así estar prevenido. Por lo tanto la ventaja es que el resultado arrojado puede tener cierta fiabilidad, resultando en un ahorro de dinero.

Predecir futuros hechos meteorológicos, en mayor o menor medida me he dado cuenta que la fase más difícil es el procesamiento de los datos y su análisis, ya que del análisis que se interprete, depende la credibilidad del modelo. Sin embargo para que el modelo funcione bien se necesita que los datos de entrada estén bien clasificados, puesto que de aquí depende que las predicciones sean buenas.

Un punto a destacar es que en la fase de predicción sale un poco costosa en tiempo de computación y en capacidad de memoria, debido a estas limitaciones no he podido probar el modelos de predicción con mas variables y datos.

Finalmente, el proceso del modelo de predicción utilizando las redes neuronales, es eficiente para la predicción de los cambios climáticos permitiendo la utilización de un bajo número de variables.

## 10 PROPUESTAS FUTURAS

En cuanto a las propuestas son varias las líneas de investigación en las que se puede aplicar las redes neuronales artificiales con el algoritmo de clasificación backpropagation. Algunos de los trabajos mencionados en el presente proyecto se pueden realizar mejorar en sus partes críticas para una mayor predicción.

Una de las líneas que se debe investigar en el futuro es el desarrollo de nuevos modelos de predicción para fenómenos climáticos como por ejemplo el Fenómeno del niño, ya que hay años en que llega a las costas ecuatorianas con mayor intensidad que en otros.

Otras de las líneas que se puede emprender en nuestro país son las predicciones para la producción de energía eléctrica, la cual se predecirá la temporada de invierno mas lluviosa o menos lluviosa ayudando a la toma de medidas preventivas ante el nivel bajo de las cotas de agua de las principales represas del país.



Un modelo para la predicción de la velocidad del viento, siendo de gran importancia para nuestra ciudad ya que el Consejo Provincial de Loja está promoviendo el proyecto sobre la producción energética de parque eólicos, permitiendo predecir con anticipación la velocidad del viento.

Modelos de predicción para actividad sísmica de un volcán, como es de conocimiento nuestro país especialmente en la región interandina, tenemos volcanes activos, por tanto es necesario el uso de tecnología avanzada que ayude a la predicción y prevención de catástrofes, permitiendo prevenir a tiempo a las personas que habitan en los alrededores de estos volcanes.

Para finalizar cabe indicar que el estudio de la redes neuronales es inmenso, y sobre estudios realizados se puede extender fácilmente, solo bastaría cambiar un poco la estructura de la red neuronal para adaptarla al nuevo problema.

## 11 REFERENCIAS

- [1] H. Basilio Sierra Araujo "Aprendizaje Automático: conceptos básicos y avanzados", 1ra. ed., Prentice Hall, Pearson, pp. 101, 2006
- [2] F.W. Op 't Landt, J.N. Kok, "Stock Price Prediction using neuronal Networks", Tesis para maestria, IEEE Trans., 1997.
- [3] Ulbricht, C. "Multi-recurrent Networks for Traffic Forecasting". Technical Report, Austrian Research Institute for Artificial Intelligence, Vienna, Austria, 1993. Disponible en: <http://www.aai.org/Papers/AAAI/1994/AAAI94-135.pdf>
- [4] D. Sun, S. Ukkusuri, R.F. Benekohal, S.T. Waller, B. Liu, "Fuzzy logic based online collision prediction system for signalized intersections", Department of Civil and Environmental Engineering, University of Illinois at Urbana Champaign, USA. 2004. Disponible en: [http://host.uniroma3.it/riviste/ats/third%20issue/issue\\_III\\_paper\\_B\\_sun\\_abstract.pdf](http://host.uniroma3.it/riviste/ats/third%20issue/issue_III_paper_B_sun_abstract.pdf)
- [5] Kyoung-jae Kim and Won Boo Lee. "Stock market prediction using artificial neural networks with optimal feature transformation", Neural Computing & Applications, Dongguk University, 2004. Disponible en: <http://www.springerlink.com/content/97xdlpxr7nradow10/>
- [6] Caren Marzban, E. Dewayne Mitchell, Gregory J. Stumpf, "A Neural Network for Tornado Diagnosis", Neural Computing and Applications. Disponible en: <http://www.nhn.ou.edu/~marzban/tda.ps>
- [7] Christos Stergiou, Dimitrios Siganos. "Neural Networks". [En línea]. Disponible en: [http://www.doc.ic.ac.uk/~nd/surprise\\_96/journal/vol4/cs11/report.html#What%20is%20a%20Neural%20Network](http://www.doc.ic.ac.uk/~nd/surprise_96/journal/vol4/cs11/report.html#What%20is%20a%20Neural%20Network)
- [8] Sergio R. Richter. Club Web Electrónica. "Gráficos de Redes Neuronales - Perceptron Multicapa". Disponible en: <http://www.webelectronica.com.ar/news21/nota09.htm>
- [9] Serrano Antonio, Soria Emilio, Martín José, "Redes neuronales Artificiales", Escuela Técnica Superior Ingeniería, Dep. Electrónica, Programa de Doctorado, 2009
- [10] Cheung Ho Yingg, "Handwritten Chinese Character Recognition", Depart. Of Electrical and Computer Engineer, University of Queensland, October 1999.
- [11] R. Rojas: "The Backpropagation Algorithm", Neural Networks, Springer-Verlag, Berlin, 1996. [En línea] Disponible en: <http://www.worldlingo.com/ma/enwiki/es/Backpropagation>
- [12] James Eldredge and Brad Hutchings, "Backpropagation Algorithm", Dept. of Electrical and Computer Eng., Brigham Young University, EEUU, 2000. [En línea]. Disponible en: <http://electronica.com.mx/neural/articulos/index.html>
- [13] Gómez R, Jiménez J., "Análisis de datos Electorales con tecnicas de aprendizaje supervisado y no supervisado", Departamento de Ingeniería Eléctrica, Universidad Carlos III de Madrid, 2005.
- [14] Instituto Nacional de Meteorología e Hidrología, INAMHI, "Proyectos Meteorológicos" en Ecuador, [En línea]. Disponible en: <http://www.inamhi.gov.ec/html/inicio.htm>
- [15] Weather Underground Inc, 2010, Pronósticos Meteorológico Histórico de Ecuador, [En línea]. Disponible en: <http://www.wunderground.com>

Adaptado por:  
Diana Lucía Poma Lima.  
Escuela de Ciencias de la Computación  
Loja-Ecuador 2010